

¿Puede un modelo de menos de 8B validar una inscripción de ramos?

Deliverable 1 · Generative Artificial Intelligence (580694) · Universidad de Concepción · 31 de agosto de 2026

Equipo: Joaquín Sepúlveda · Renato Saavedra · Lucas Saldivia • Repositorio: github.com/Luquitas02/genai-inscripcion-ramos

LA TAREA

Dado el historial académico de un estudiante y una consulta escrita como la escribiría una persona real, decidir si puede inscribir el ramo y **citar la regla que sostiene la decisión**.

“oye, me falta Cálculo 2 pero la estoy tomando ahora, ¿podría inscribir ecuaciones el que viene?”

{"decision":"condicional", "regla":"R-DEPENDE-APROBACION"}

Ecuaciones Diferenciales exige Cálculo II, que está *en curso*. Hoy no está aprobada y el próximo semestre sí. Por este semestre la respuesta sería no, con el mismo expediente.

Qué cuenta como correcto

Coincidencia exacta de los dos campos contra un verificador determinista, y se reportan por separado.

La decisión

sí puede inscribir · no algo lo impide y no se resuelve solo · condicional puede, sujeto a aprobar lo que cursa ahora *o* a que proceda la excepción por carga bajo el mínimo.

La regla

El código de la asignatura que falta (527150) o el artículo que decide: R-DEPENDE-APROBACION, R-EXCEPCION-PRERREQ, R-CREDITOS-MINIMOS, R-TOPE-MAX, R-ESPECIAL-*, R-SIN-IMPEDIMENTO. Quince en los 60 casos: 8 códigos, 7 artículos.

DOMINIO Y DATOS

Malla de Ingeniería Civil Industrial UdeC, congelada como fuente única para los cuatro entregables. **61** asignaturas, **227** créditos, cadenas de prerrequisitos de hasta **6** niveles, **14** ramos con umbral de créditos aprobados y 4 reglas globales.

Auditada antes de usarse: sin ciclos, créditos consistentes, un umbral inalcanzable detectado y corregido contra el portal.

CÓMO SE MIDE

60 casos sintéticos. La respuesta de cada uno la fija el verificador. Decisiones balanceadas 21/21/18, así que **la mejor constante trivial rinde 35,0 %**.

Generación hacia atrás

Se elige primero qué regla debe decidir y se construye el historial que la produce. El caso se descarta si el verificador no confirma lo declarado.

Control de sesgo


Cruce rasgo × respuesta antes de medir: ningún rasgo superficial de la pregunta predice la decisión por sí solo.

Tres condiciones

Zero-shot en prosa, zero-shot con la pregunta reducida a código y período, y few-shot con tres ejemplos resueltos.

CADA MODELO COLAPSA EN UNA CATEGORÍA DISTINTA

Predicciones en zero-shot con prosa, sobre 60 casos:



sí no condicional

Los tres tienen sesgos distintos e incompatibles. **Ninguno deduce la respuesta del expediente**. Cada uno se vuelca sobre una sola categoría.

RESULTADOS

Modelo	Condición	Dec.	Regla	Ambas
Granite 8B	zero, prosa	50,0	36,7	35,0
	zero, reducida	36,7	21,7	21,7
	few-shot	45,0	38,3	38,3
Qwen 7,6B	zero, prosa	40,0	8,3	8,3
	zero, reducida	38,3	6,7	6,7
	few-shot	43,3	31,7	31,7
Phi 3,8B	zero, prosa	43,3	6,7	5,0
	zero, reducida	35,0	5,0	5,0
	few-shot	35,0	23,3	16,7
Constante trivial		35,0	30,0	30,0

Porcentajes sobre 60 casos; generación determinista, reproducida idéntica al repetirla. La constante trivial responde siempre lo mismo sin leer nada: NO para la decisión, SÍ con R-SIN-IMPEDIMENTO para el par.

Seis de las nueve condiciones quedan por debajo de esa constante en la métrica conjunta. La mejor le gana por 8,3 puntos.

FACTIBILIDAD DE EJECUCIÓN

Hardware	GPU T4 gratuita (Colab), cuantización 4 bits
VRAM usada	≈5 GB de 15 disponibles
Tiempo por caso	4,2 s (Phi) – 15,0 s (Granite)
Tokens de entrada	3 253 – 3 963
Corrida completa	9 condiciones, ≈81 min de inferencia
Salidas con JSON válido	539 / 540

El formato casi nunca falló. Los errores fueron de razonamiento.

DIAGNÓSTICO DE LA FALLA

E1 · No representa “cursándola ahora”

De las 21 condicional esperadas, Qwen produce 3 en todo el set y Phi produce 31. Ninguno se acerca a las 21. Los 18 casos con un prerrequisito en curso se parten 12 condicional / 6 no según el período preguntado. El mejor modelo acierta 12 de esos 18, lo mismo que da responder condicional a todos sin mirar el período.

E2 · Depende de que la pregunta le apunte

Al reducir la consulta a código y período (el historial completo sigue en el prompt), el acierto **cae en los tres modelos**: −1,7, −8,3 y −13,3 puntos. No localizan el dato si nadie se lo señala.

E3 · No copia un identificador que tiene delante

Phi-3.5-mini degrada la cadena R-CREDITOS-MINIMOS, escrita literalmente en su prompt, en formas inexistentes:

R-CREDITOS-MINIMISMU, R-CREDITOS-MINIMISIMO, R-CREDITOS-MINIMISMUDA

Más invenciones puras (R-8-CURSADO, R-0321) y combinaciones ilegales de prefijo y código. **35 instancias en Phi; 0 en Qwen; 4 en Granite.**

E4 · Se contradice dentro de su propia respuesta

Responde sí citando una regla que bloquea: hasta **28 de 60** en Qwen con la pregunta reducida, usando 4 identificadores para los 60 casos.

Los ejemplos ordenan la salida pero no mejoran la decisión.

El few-shot elimina las contradicciones (Qwen y Granite a 0), casi elimina las alucinaciones (Phi de 35 a 4) y sube el acierto de regla en los tres (+16,6, +23,4, +1,6 puntos). La decisión no mejora en ninguno.

MODELOS CANDIDATOS

Modelo	Par.	Rol
Granite-3.1-8B-Instruct IBM	8,0 B	mejor de los tres; base para el harness
Qwen2.5-7B-Instruct Alibaba	7,6 B	multilingüe; 0 alucinaciones
Phi-3.5-mini-instruct Microsoft	3,8 B	prueba de si la capacidad es necesaria

Sobre el candidato bajo el techo. Propusimos Phi-3.5-mini, con menos de la mitad de los parámetros permitidos, bajo la hipótesis de que una salida de veinte tokens no necesita capacidad sobrante. **La medición la refuta**. Es el peor de los tres y el único que corrompe identificadores, aunque también el más rápido (3× sobre Granite).

CÓMO CRECE LA TAREA

La dificultad es un eje medible (profundidad, ambigüedad, distractores, reglas simultáneas), así que se endurece sin cambiar de tema.

D2 prompt y contexto contra E1 y E2 D3 consulta al grafo contra E3, validador contra E4 D4 puntaje final contra este baseline.