

De 16,7 % a 58,3 % en la validación de inscripción de ramos con un modelo de 3,8B

Deliverable 2 · Generative Artificial Intelligence (580694) · Universidad de Concepción · 30 de septiembre de 2026  
Equipo: Joaquín Sepúlveda · Renato Saavedra · Lucas Saldivia • Modelo: microsoft/Phi-3.5-mini-instruct, 3,8B, cuantizado a 4 bits, T4 de Colab  
Repositorio: github.com/Luquitas02/genai-inscripcion-ramos • Video: <PEGAR LINK>

LA TAREA Y LA FALLA QUE SE ATACA

Dado el historial de un estudiante y una pregunta escrita como la escribiría una persona, decidir si puede inscribir un ramo y citar la regla que lo sostiene. Salida de dos campos, corrección por coincidencia exacta, 60 casos balanceados. Es la misma tarea del Deliverable 1, con el mismo conjunto y el mismo criterio.

El Deliverable 1 midió que el baseline no razona. Con prompting directo, Phi acierta 16,7 % de los casos en ambos campos, bajo el piso de 30,0 % que consigue quien responde siempre lo mismo. Se diagnosticaron cuatro mecanismos: no representa el estado "cursándola ahora" (E1), depende de que la pregunta le apunte al dato (E2), inventa identificadores (E3) y se contradice entre decisión y regla (E4).

POR QUÉ ESTE MODELO, Y NO LOS OTROS DOS

El Deliverable 1 propuso tres candidatos de familias distintas. El criterio de selección se escribió antes de mirar los datos: acierto de decisión fuera de la categoría donde cada modelo colapsa. Esa métrica descuenta lo que gana quien responde siempre lo mismo.

|                 | params | fuera del colapso | ambas (D1) |
|-----------------|--------|-------------------|------------|
| Phi-3.5-mini    | 3,8B   | 40,5              | 16,7       |
| Mistral-7B-v0.3 | 7,2B   | 19,0              | 38,3       |
| Qwen2.5-7B      | 7,6B   | sin crudo         | 31,7       |


Phi acierta más del doble que Mistral con la mitad de los parámetros. Su acierto conjunto en el Deliverable 1 es el más bajo de los tres. Mistral responde "sí" en 50 de los 60 casos y acierta los 18 que efectivamente lo son, así que queda sobre el piso trivial sin haber leído el expediente. Phi reparte sus respuestas entre las tres categorías. Se eligió Phi porque el sistema necesita un modelo que distinga categorías.

Qwen queda fuera por ser el más grande de los tres y quedar bajo Mistral en la métrica conjunta. Sus archivos crudos se perdieron en agosto, así que su columna de colapso no se pudo recalcular. Phi es además el más chico de los tres candidatos.

El sistema completo corre en la T4 gratuita de Colab, el hardware declarado en el Deliverable 1, a 1,6 segundos por caso y 1,6 minutos los sesenta.

LA INTERVENCIÓN

Descomposición en tres pasos con contexto enfocado y salida restringida. El baseline recibe 3.862 tokens y debe hacer todo en una pasada. Acá cada paso recibe solo lo suyo.



El **paso 1** ataca E2. Ve la pregunta y los 61 pares de código y nombre, sin historial ni reglas. El **paso 2** ataca E1. Arma una ficha de ocho campos sobre un solo ramo y descarta las 25 asignaturas del historial que no lo tocan. El **paso 3** ataca E3 y E4. La regla debe salir de una lista cerrada que incluye los códigos de los prerrequisitos del caso, y la decisión se deriva de esa regla.

DOS MECANISMOS ELIMINADOS POR CONSTRUCCIÓN

Se verificó sobre los 60 casos que la decisión queda determinada por la regla, sin una sola ambigüedad. Pedir los dos campos le daba al modelo un grado de libertad que el dominio no tiene. Al derivar la decisión y restringir la regla, E3 y E4 desaparecen.

| sobre 240 respuestas donde el modelo decide |   |
|---------------------------------------------|---|
| identificadores inventados (E3)             | 0 |
| contradicciones decisión/regla (E4)         | 0 |
| salidas sin JSON legible                    | 0 |

En el baseline zero-shot, Phi inventaba identificadores en 18 de 60 casos.

RESULTADOS SOBRE LOS 60 CASOS

Las variantes mueven una pieza por vez del modelo al código, así que la diferencia entre dos filas mide lo que esa pieza aporta.

|                                 | decisión    | regla       | ambas       | tok/caso     |
|---------------------------------|-------------|-------------|-------------|--------------|
| baseline few-shot               | 35,0        | 23,3        | 16,7        | 3.862        |
| constante trivial               | 35,0        | 30,0        | 30,0        | —            |
| ficha y reglas al modelo        | 45,0        | 25,0        | 25,0        | 6.072        |
| ficha al código                 | 45,0        | 28,3        | 28,3        | 2.743        |
| <b>ficha y reglas al código</b> | <b>71,7</b> | <b>58,3</b> | <b>58,3</b> | <b>1.153</b> |
| con el paso 1 resuelto          | 100,0       | 100,0       | 100,0       | 1.153        |

El sistema triplica el baseline y es además la condición más barata. Usa **1.153 tokens por caso contra 3.862** del baseline, y 1,6 segundos contra 4,2. Con un tercio del cómputo, la mejora no se explica por haber gastado más.

Los 60 casos se generaron desde la regla que debía decidir, así que cada familia se cuenta por separado. El sistema mejora en siete de las ocho, y la que empeora está declarada más abajo.

ESTRATEGIAS ALTERNATIVAS EVALUADAS

El paso 3 se midió con la ficha verdadera de cada caso, bajo cuatro versiones del prompt, contra un techo demostrado de 60/60.

| versión del prompt del paso 3 | ambas | regla dominante |
|-------------------------------|-------|-----------------|
| completo                      | 26,7  | R-EXCEPCION 38  |
| sin el bloque de reglas       | 31,7  | R-DEPENDE 49    |
| sin ejemplos                  | 15,0  | R-EXCEPCION 60  |
| mínimo                        | 30,0  | R-DEPENDE 47    |

El bloque de reglas globales dictaba la respuesta por su posición. Era la última prosa del prompt y la única que nombraba un valor de decisión. Sacarlo vale 5 puntos. Aun así el modelo sigue colapsando en una categoría. Con la ficha perfecta delante aplica las reglas al 31,7 % y el código lo hace al 100 %. Por esa diferencia las reglas quedaron en el código.

En el paso 1 los ejemplos bajan el acierto de ramo de 51,7 % a 45,0 %, así que se descartaron.

DÓNDE SE ROMPE, Y POR QUÉ

|                                              |          |
|----------------------------------------------|----------|
| casos donde el paso 1 acierta ramo y periodo | 28 de 28 |
| casos donde el paso 1 falla                  | 7 de 32  |

**Todo el error restante es extracción.** El paso 1 identifica el ramo en 31 de 60 casos, y se degrada con la forma de nombrarlo: 13/20 con el nombre completo, 10/20 abreviado, 8/20 coloquial.

**Caso de falla, elegido por regla escrita antes de medir** (el primero de nivel 3 cuyo baseline falla). La pregunta es "programación, la reprobé, ¿puedo tomar Optimización 1 ahora ya?". El ramo consultado es 580315. El paso 1 devolvió 503203, que la frase menciona de contexto y que además es el prerrequisito que bloquea. Los pasos 2 y 3 evaluaron 503203 y respondieron que sí, porque un ramo reprobado se puede volver a inscribir. La respuesta es correcta para ese ramo y ese ramo no era el consultado. Es el mecanismo E2 del Deliverable 1.

El **paso 2 tampoco puede leer el expediente** aun con el ramo correcto: estado del ramo 0/60, créditos aprobados 0/60, prerrequisitos 7/60. Por eso la ficha la arma el código.

LÍMITES DECLARADOS

**Una categoría empeora.** En los 12 casos con prerrequisito en curso preguntando por el próximo periodo, el sistema baja de 6/12 a 3/12. Los 12 tienen la misma respuesta correcta, y el baseline la dio en 6 de ellos respondiendo "condicional". Las 9 fallas del sistema son las 9 veces que el paso 1 tomó el ramo equivocado.

**Filtración del conjunto.** Los 9 casos de R-EXCEPCION-PRERREQ tienen cero créditos inscritos y los otros 51 entre 12 y 24, con el umbral en 8, así que el conjunto no prueba la frontera de esa regla.

**Selección sobre el mismo conjunto.** Las versiones del prompt se eligieron por ablación sobre los mismos 60 casos. Con n=60, diferencias de dos a cuatro casos no deben leerse como efectos firmes.

**Desviación declarada.** El plan del Deliverable 1 reservaba la consulta al grafo para el Deliverable 3. Se adelantó porque la ablación mostró que el modelo no aplica las reglas, y el Deliverable 3 pasa a atacar la extracción. Un dominio y 60 casos, sin cambios respecto al Deliverable 1.