

De 16,7 % a 58,3 % en la validación de inscripción de ramos con un modelo de 3,8B y el reglamento en código

Deliverable 2 · Generative Artificial Intelligence (580694) · Universidad de Concepción · 30 de septiembre de 2026
Equipo: Joaquín Sepúlveda · Renato Saavedra · Lucas Saldivia • **Modelo:** microsoft/Phi-3.5-mini-instruct (revisión 2fe1924), 3,8B, NF4 de 4 bits, T4 de Colab
Repositorio: github.com/Luquitas02/genai-inscripcion-ramos • **Video:** https://www.youtube.com/watch?v=GvLJfazDHvs

LA TAREA Y LA FALLA QUE SE ATACA

Dado el historial de un estudiante y una pregunta escrita como la escribiría una persona, decidir si puede inscribir un ramo y citar la regla que lo sostiene. Salida de dos campos, corrección por coincidencia exacta, 60 casos con las tres decisiones en partes casi iguales (21 no, 21 condicional, 18 sí). La tarea, los casos y el criterio son los del Deliverable 1.
Con prompting directo, en su mejor condición (few-shot), Phi acierta 16,7 % de los casos en ambos campos, bajo el 30,0 % que consigue quien responde siempre "sí". Se diagnosticaron cuatro mecanismos: no representa el estado "cursándola ahora" (E1), depende de que la pregunta le apunte al dato (E2), inventa identificadores (E3) y se contradice entre decisión y regla (E4).

ELECCIÓN DEL MODELO


El Deliverable 1 propuso tres candidatos de familias distintas, con Mistral como base. En el sistema final el modelo solo hace el paso 1, así que los tres se midieron haciendo ese trabajo, con el mismo sistema y los mismos 60 casos. La regla de elección se subió al repositorio antes de correr (PROTOCOL_30SEP.md). Se cambia a un modelo de 7B solo si acierta al menos 6 casos más que Phi, con McNemar $p < 0,05$.

	params	ramo (paso 1)	ambas	s/caso
Phi-3.5-mini	3,8B	31	35	1,6
Mistral-7B-v0.3	7,2B	32	36	3,1
Qwen2.5-7B	7,6B	41	42	2,8

Mistral acierta un caso más con el doble de parámetros. Qwen acierta 7 más, con $p = 0,17$, así que no cumple la regla y se mantiene Phi, el más pequeño. Qwen sí identifica mejor el ramo (41 contra 31, $p = 0,03$), y esa brecha es la que el Deliverable 3 tiene que cerrar con Phi. El Deliverable 1 descartó a Phi cuando el modelo decidía, por su acierto conjunto y por inventar identificadores. En el paso 1 un código que no está en la malla se descarta. Phi no devolvió ninguno y Qwen devolvió 2.
El sistema corre en la T4 gratuita de Colab, el hardware declarado en el Deliverable 1, a 1,6 segundos por caso.

LA INTERVENCIÓN

Descomposición en tres pasos y uso de herramientas. El baseline recibe 3.862 tokens y hace todo en una llamada. En el sistema el modelo lee la pregunta en prosa, que es lo que el código no puede hacer, y el código aplica el reglamento con la misma lógica del verificador que etiqueta los 60 casos. La salida sigue siendo decisión y regla, evaluadas igual que en el Deliverable 1.



El **paso 1** aísla la lectura de la prosa y permite medirla sola. Ve la pregunta y los 61 pares de código y nombre, sin historial ni reglas. El **paso 2** lleva E1 y E2 al código. Arma una ficha de ocho campos sobre un solo ramo, con el estado "inscrita" de cada prerequisite, así que el dato que decide queda a la vista aunque la pregunta no lo nombre. Deja fuera unas 25 asignaturas del historial que no tocan ese ramo. En el **paso 3** el código aplica el reglamento y entrega regla y decisión, así que E3 y E4 no pueden ocurrir.

E3 Y E4 EN EL SISTEMA

En el sistema la regla y la decisión las entrega el código, así que E3 y E4 no ocurren por diseño. Antes se probó un paso intermedio, donde el modelo elegía la regla de una lista cerrada y la decisión se calculaba desde ella. En sus cuatro corridas de 60 casos no inventó ningún identificador y todas sus salidas fueron JSON legible. En el baseline, Phi inventaba identificadores en 18 de 60 casos (zero-shot) y en 3 (few-shot), sin contar R-TOPE-MIN, que el prompt ofrecía. El Deliverable 1 reportaba 35 y 4 con la corrida de agosto y contando esa regla. Relanzada, da 33 y 3.

LO QUE MUESTRA EL VIDEO

Corre en vivo en la T4 los casos 40 a 49, sin saltarse ninguno. Son los diez primeros de nivel 3, el más difícil: el ramo se nombra de forma coloquial, a veces junto a otro, y el historial trae distractores. En cada caso se ven la respuesta del baseline y la del sistema sobre la misma pregunta, y cada salida se compara con la corrida guardada en el repositorio. El 40 es el caso de falla y se ve completo. demo_colab.ipynb lo reproduce.

RESULTADOS CONTRA EL BASELINE

	decisión	regla	ambas	tok/caso
baseline few-shot	35,0	23,3	16,7	3.862
responder siempre "sí"	30,0	30,0	30,0	—
3 pasos, todo el modelo	45,0	25,0	25,0	6.072
ficha por código	45,0	28,3	28,3	2.743
ficha y reglas por código	71,7	58,3	58,3	1.153
techo, paso 1 perfecto	100,0	100,0	100,0	1.153
60 casos nuevos, otra semilla del generador				
baseline few-shot	51,7	35,0	30,0	3.836
ficha y reglas por código	71,7	61,7	61,7	1.153

El sistema sube de 16,7 % a 58,3 % y supera por 28,3 puntos a la constante. En los 39 casos donde difieren, gana 32 y el baseline 7 (McNemar exacto, $p < 0,001$). Usa **1.153 tokens por caso contra 3.862**, y 1,6 segundos contra 4,2. En 60 casos nuevos, generados después de fijar el sistema, gana 29 a 10 ($p = 0,003$). Ocho preguntas se repiten del conjunto original. Sin ellas el sistema acierta 30 de 52 y el baseline 16.

El techo sale 100 % por construcción, porque el código es el verificador. Por familia de casos, según la regla que decide, el sistema mejora en siete de ocho:

familia	correcta	n	baseline	sistema
sin impedimento	sí	18	2	13
excepción de prerequisite	condicional	9	0	8
prerequisite en curso, próximo	condicional	12	6	3
prerequisite faltante	no	6	2	3
prerequisite en curso, actual	no	6	0	1
créditos mínimos	no	3	0	3
requisito especial	no	3	0	2
tope de créditos	no	3	0	2
total		60	10	35

ESTRATEGIAS ALTERNATIVAS EVALUADAS

Se midió el paso 3 con el modelo sobre la ficha verdadera, con la que el código acierta 60/60.

versión del prompt del paso 3	ambas	regla dominante
completo	26,7	R-EXCEPCION-PRERREQ 38
sin el bloque de reglas	31,7	R-DEPENDE-APROBACION 49
sin ejemplos	15,0	R-EXCEPCION-PRERREQ 60
mínimo	30,0	R-DEPENDE-APROBACION 47

En las cuatro versiones una regla acapara entre 38 y 60 respuestas. Con la ficha verdadera delante aplica las reglas al 31,7 % y el código lo hace al 100 %. Por esa diferencia las reglas quedaron en el código.

En el paso 1 los ejemplos bajan el acierto de ramo de 51,7 % a 45,0 % (4 casos), y se descartaron. Con 60 casos son diferencias pequeñas y se eligió sobre el mismo conjunto. Por eso se midió además en casos nuevos.

DÓNDE SE ROMPE, Y POR QUÉ

acierto del sistema si el paso 1 acierta ramo y período	28 de 28
acierto del sistema si el paso 1 se equivoca	7 de 32

Con ramo y período correctos el código reproduce al verificador, así que **todo el error viene del paso 1**. Los 7 aciertos con el paso 1 equivocado son casos donde el ramo o el período equivocado llevan a la misma respuesta. El paso 1 identifica el ramo en 31 de 60 casos y se degrada con la forma de nombrarlo: 13/20 con el nombre completo, 10/20 abreviado, 8/20 coloquial.

Caso de falla, el primero de nivel 3, elegido por una regla escrita antes de correr el sistema. La pregunta dice "...programación, la reprobé, ¿puedo tomar Optimización 1 ahora ya?". Nombró dos ramos y el prerequisite va primero. "programación" coincide con el nombre del catálogo y "Optimización 1" no coincide con "Optimización I". El prompt no distingue el ramo consultado del que se nombra de contexto, y el modelo devolvió 503203, el código de Programación. Los pasos 2 y 3 evaluaron Programación y respondieron que sí. En las 20 preguntas que nombran otro ramo antes del consultado, el paso 1 acierta 3. En las otras 40 acierta 28.

Cuando el modelo armaba la ficha, aun con el ramo correcto, acertó estado 0/60 y créditos aprobados 0/60. Nunca respondió "no cursada", el estado real en los 60. Por eso la ficha la arma el código.

LÍMITES DECLARADOS

E1 pasa a ser un problema de extracción. En los 18 casos con prerequisite en curso el sistema acierta 4 y el baseline 6. Estas preguntas nombran primero el ramo en curso, y el paso 1 identifica el consultado en 3 de 18. En los 12 que preguntan por el próximo período el sistema baja de 6 a 3. La respuesta correcta de los 12 es "condicional", que el baseline da con frecuencia, y así acierta 6. Las 9 fallas del sistema tienen el ramo equivocado.

Atajo en el conjunto. Los 9 casos de R-EXCEPCION-PRERREQ tienen cero créditos inscritos y los otros 51 entre 12 y 24, con el umbral en 8, así que el conjunto no prueba la frontera de esa regla.

Desviación declarada. En el Deliverable 1 el modelo leía la pregunta y el expediente y decidía. En este sistema el modelo solo identifica el ramo y el período, y la ficha y la decisión las calcula el código con la lógica del verificador que etiqueta los casos. Con el ramo correcto, el código evita E1 a E4, y el 58,3 % mide la extracción que hace el modelo. El Deliverable 1 planeaba atacar E1 con el prompt y dejaba el grafo y un validador de la salida para el Deliverable 3. Se cambió porque la ablación mostró que el modelo no aplica las reglas, y el Deliverable 3 pasa a atacar la extracción.