

De 16,7 % a 58,3 % en la validación de inscripción de ramos con un modelo de 3,8B

Deliverable 2 · Generative Artificial Intelligence (580694) · Universidad de Concepción · 30 de septiembre de 2026
Equipo: Joaquín Sepúlveda · Renato Saavedra · Lucas Saldivia • Modelo: microsoft/Phi-3.5-mini-instruct (revisión 2fe1924), 3,8B, NF4 de 4 bits, T4 de Colab
Repositorio: github.com/Luquitas02/genai-inscripcion-ramos • Video: PEGAR-LINK-AQUI

LA TAREA Y LA FALLA QUE SE ATACA

Dado el historial de un estudiante y una pregunta escrita como la escribiría una persona, decidir si puede inscribir un ramo y citar la regla que lo sostiene. Salida de dos campos, corrección por coincidencia exacta, 60 casos balanceados. Es la misma tarea del Deliverable 1, con el mismo conjunto y el mismo criterio.

Con prompting directo, en su mejor condición (few-shot), Phi acierta 16,7 % de los casos en ambos campos, bajo el piso de 30,0 % que consigue quien responde siempre lo mismo. Se diagnosticaron cuatro mecanismos: no representa el estado "cursándola ahora" (E1), depende de que la pregunta le apunte al dato (E2), inventa identificadores (E3) y se contradice entre decisión y regla (E4).

ELECCIÓN DEL MODELO

El Deliverable 1 propuso tres candidatos de familias distintas. El criterio se fijó antes de recalcular los crudos recuperados, cuando el plan era que el modelo decidiera. Es el acierto de decisión fuera de la categoría donde cada modelo colapsa, en few-shot, y descuenta lo que gana quien responde siempre lo mismo.


	params	fuera del colapso	ambas (D1)
Phi-3.5-mini	3,8B	40,5	16,7
Mistral-7B-v0.3	7,2B	19,0	38,3
Qwen2.5-7B	7,6B	sin crudo	31,7

El Deliverable 1 descartó a Phi por su acierto conjunto, el más bajo de los tres. Mistral responde "sí" en 50 de los 60 casos y acierta 17 de los 18 que lo son, así que su acierto conjunto sale del colapso y no de leer el expediente. Phi reparte sus respuestas entre las tres categorías. Qwen, el más grande, no se pudo medir con este criterio porque sus crudos se perdieron en agosto. En el sistema final el modelo solo extrae el ramo, y el Deliverable 3 comparará esa extracción entre modelos.

El sistema corre en la T4 gratuita de Colab, el hardware declarado en el Deliverable 1, a 1,6 segundos por caso.

LA INTERVENCIÓN

Descomposición en tres pasos y uso de herramientas. El baseline recibe 3.862 tokens y hace todo en una llamada. En el sistema el modelo lee la pregunta en prosa, que es lo que el código no puede hacer, y el código aplica el reglamento con la misma lógica del verificador que etiqueta los 60 casos. La salida sigue siendo decisión y regla, evaluadas igual que en el Deliverable 1.



El **paso 1** aísla la lectura de la prosa, donde vive E2, y permite medirla sola. Ve la pregunta y los 61 pares de código y nombre, sin historial ni reglas. El **paso 2** lleva E1 al código. Arma una ficha de ocho campos sobre un solo ramo, con el estado "inscrita" de cada prerequisite, y descarta las 25 asignaturas que no lo tocan. El **paso 3** elimina E3 y E4. La regla sale de una lista cerrada y la decisión se deriva de ella.

DOS MECANISMOS ELIMINADOS POR CONSTRUCCIÓN

En los 60 casos la regla determina la decisión sin ambigüedad. Por eso basta pedir la regla, elegida de una lista cerrada, y calcular la decisión. Así quedó en las variantes donde el modelo hace el paso 3:

240 respuestas del modelo en el paso 3	
identificadores inventados (E3)	0
contradicciones decisión/regla (E4)	0
salidas sin JSON legible	0

En el baseline, Phi inventaba identificadores en 18 de 60 casos en zero-shot y en 3 en few-shot, sin contar R-TOPE-MIN, que el prompt ofrecía. El Deliverable 1 lo contaba.

LO QUE MUESTRA EL VIDEO

Corre en vivo en la T4 los casos 40 a 49, los diez primeros de nivel 3, sin saltarse ninguno. El 40 es el caso de falla y se ve completo. Cada salida del modelo se compara con la corrida guardada en el repositorio, y demo.colab.ipynb lo reproduce.

RESULTADOS SOBRE LOS 60 CASOS

Las variantes pasan una pieza por vez del modelo al código.

	decisión	regla	ambas	tok/caso
baseline few-shot	35,0	23,3	16,7	3.862
constante trivial	35,0	30,0	30,0	—
3 pasos, todo el modelo	45,0	25,0	25,0	6.072
ficha por código	45,0	28,3	28,3	2.743
ficha y reglas por código	71,7	58,3	58,3	1.153
techo, paso 1 correcto	100,0	100,0	100,0	1.153

El sistema sube de 16,7 % a 58,3 % y supera por 28,3 puntos a la constante. En los 39 casos donde difieren, gana 32 y el baseline 7 (McNemar exacto, $p < 0,001$). Usa **1.153 tokens por caso contra 3.862**, y 1,6 segundos contra 4,2.

El techo sale 100 % por construcción, porque el código es el verificador. Por familia de casos, según la regla que decide, el sistema mejora en siete de ocho:

familia	correcta	n	baseline	sistema
sin impedimento	sí	18	2	13
excepción de prerequisite	condicional	9	0	8
prerequisite en curso, próximo	condicional	12	6	3
prerequisite reprobado	no	6	2	3
prerequisite en curso, actual	no	6	0	1
créditos mínimos	no	3	0	3
requisito especial	no	3	0	2
tope de créditos	no	3	0	2
total		60	10	35

ESTRATEGIAS ALTERNATIVAS EVALUADAS

El paso 3 se midió con la ficha verdadera de cada caso, con la que el código acierta 60/60.

versión del prompt del paso 3	ambas	regla dominante
completo	26,7	R-EXCEPCION 38
sin el bloque de reglas	31,7	R-DEPENDE 49
sin ejemplos	15,0	R-EXCEPCION 60
mínimo	30,0	R-DEPENDE 47

Sacar el bloque de reglas globales sube el acierto 5 puntos, que son 3 casos, y cambia la regla dominante. El modelo sigue colapsando en una sola. Con la ficha perfecta delante aplica las reglas al 31,7 % y el código lo hace al 100 %. Por esa diferencia las reglas quedaron en el código.

En el paso 1 los ejemplos bajan el acierto de ramo de 51,7 % a 45,0 % (4 casos), y se descartaron. Con 60 casos son diferencias chicas, y se eligió sobre el mismo conjunto.

DÓNDE SE ROMPE, Y POR QUÉ

casos donde el paso 1 acierta ramo y periodo	28 de 28
casos donde el paso 1 falla	7 de 32

Con ramo y periodo correctos el código reproduce al verificador, así que **todo el error viene del paso 1**. Identifica el ramo en 31 de 60 casos y se degrada con la forma de nombrarlo: 13/20 con el nombre completo, 10/20 abreviado, 8/20 coloquial.

Caso de falla, el primero de nivel 3, elegido por una regla escrita antes de correr el sistema. La pregunta es "programación, la reprobé, ¿puedo tomar Optimización 1 ahora ya?". Nombra dos ramos y el prerequisite va primero. "programación" coincide letra por letra con el catálogo y "Optimización 1" no coincide con "Optimización I". El prompt no distingue el ramo consultado del que se nombra de contexto, y el modelo devolvió 503203. Los pasos 2 y 3 evaluaron ese ramo y respondieron que sí, porque un reprobado se vuelve a inscribir. Esa respuesta vale para Programación y no para Optimización I. Es un patrón. En las 20 preguntas que nombran otro ramo antes del consultado, el paso 1 acierta 3. En las otras 40 acierta 28.

El paso 2 tampoco lee el expediente con el ramo correcto. Acierta estado 0/60, créditos aprobados 0/60 y prerequisites 7/60. Nunca responde "no cursada", que es el estado real en los 60, y en créditos aprobados devuelve los de un ramo (3 a 5) en vez de la suma (30 a 163). Por eso la ficha la arma el código.

LÍMITES DECLARADOS

E1 pasa a ser un problema de extracción. En los 18 casos con prerequisite en curso el sistema acierta 4 y el baseline 6. Estas preguntas nombran primero el ramo en curso, y el paso 1 identifica el consultado en 3 de 18. En los 12 que preguntan por el próximo periodo el sistema baja de 6 a 3. Los 12 tienen la misma respuesta, y el baseline la dio 6 veces respondiendo "condicional". Las 9 fallas del sistema tienen el ramo equivocado.

Atajo en el conjunto. Los 9 casos de R-EXCEPCION-PRERREQ tienen cero créditos inscritos y los otros 51 entre 12 y 24, con el umbral en 8, así que el conjunto no prueba la frontera de esa regla.

Desviación declarada. El Deliverable 1 planeaba atacar E1 con el prompt y reservaba el grafo y el validador para el Deliverable 3. Se adelantaron porque la ablación mostró que el modelo no aplica las reglas, y el Deliverable 3 pasa a atacar la extracción. El dominio y los 60 casos son los mismos del Deliverable 1.