# Un sistema de tres agentes sobre Phi-3.5-mini (3,8B) acierta 88,0 % contra 64,0 % del D2 en 150 casos, y 91,1 % contra 65,6 % en 180 casos sellados

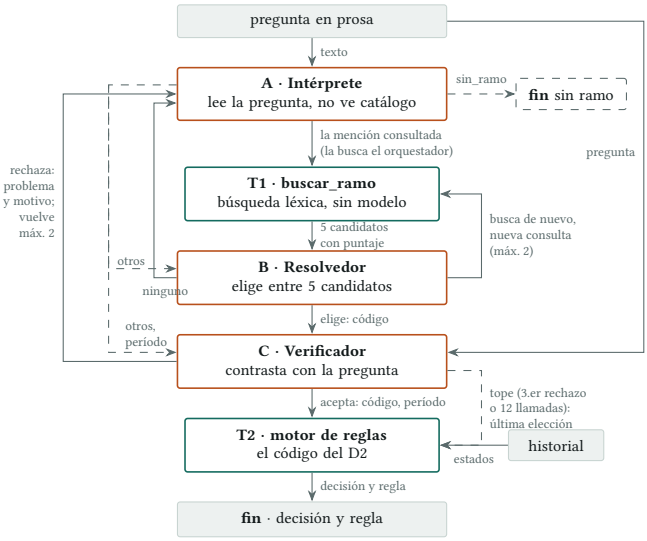
**Deliverable 3** · Generative Artificial Intelligence (580694) · Universidad de Concepción · 31 de octubre de 2026
**Grupo 3:** Joaquín Sepúlveda · Renato Saavedra · Lucas Saldivia • **Modelo:** `microsoft/Phi-3.5-mini-instruct` (revisión `2fe1924`), 3,8B, NF4, T4 de Colab, en los tres agentes
**Repositorio:** `github.com/Luquitas02/genai-inscripcion-ramos` • **Video:** `https://youtu.be/UYir4ZV0sjM`

## TAREA, FALLA Y CONTINUIDAD

La tarea y el criterio son los del D1 y el D2. Dado el historial de un estudiante y una pregunta en prosa, el sistema decide si puede inscribir el ramo y cita la regla. Un caso es correcto si acierta decisión y regla (acierto conjunto). El D2 acertaba 35 de los 60 casos del D1. Su modelo solo leía la pregunta, y el programa armaba la ficha del estudiante y aplicaba el reglamento. Así desaparecieron los errores E1 a E4 del D1. El D1 dejaba E3 y E4 para el D3. Con el ramo y el período correctos el programa acierta siempre, porque las etiquetas salen de ese mismo programa. Todo el error restante estaba en la lectura de la pregunta, el paso 1 del D2. El D3 rehace esa lectura con tres agentes sobre el mismo Phi.

En esos 60 casos la lectura del D2 fallaba por tres mecanismos. **M1** es copiar el código del ramo. Con el nombre exacto del ramo en la pregunta, Phi acertaba 18 de 34, porque copiaba mal un código de seis dígitos desde la lista de los 61 ramos. **M2** es separar el ramo consultado de los otros. Si la pregunta nombra otro ramo antes del consultado, acertaba 3 de 20. **M3** es el período. Si la pregunta dice que otro ramo se cursa "ahora", Phi tomaba ese "ahora" como el período del ramo consultado.

## EL GRAFO DE AGENTES




Borde naranjo, agentes, cada uno con su prompt en `prompts/<agente>.md`. Borde verde, herramientas. Las vueltas al Intérprete, por rechazo o por `ninguno`, suman máx. 2. Al llegar a un tope, o si A responde `sin_ramo` tras un rechazo, T2 recibe la última elección aunque esté rechazada. La punteada de la izquierda lleva otros ramos y período de A a B y C. Un orquestador en código ejecuta la decisión de cada agente.

Traza real (conjunto nuevos, caso 49). T1 da un puntaje léxico, y 1,50 es coincidencia exacta:

"...me falta programación pero la estoy cursando, ¿puedo tomar opti I el que viene?"

```
A⟶T1 {"consultado": "opti I", "otros": ["programación"], "frase_periodo": "el
que viene", "periodo": "proximo"}
T1⟶B 580315 Optimización I 0,60 · 201 Complementaria 1 0,55 · ...
B⟶T1 {"accion": "buscar", "consulta": "Optimización I"}
T1⟶B 580315 Optimización I 1,50 · 580325 Optimización II 0,93 · ...
B⟶C {"accion": "elegir", "codigo": "580315"}
C⟶T2 {"cita_ramo": "Optimización I", "cita_periodo": "proximo (2027-1)",
"accion": "aceptar"}
T2 condicional · R-DEPENDE-APROBACION (correcta)
```

## LOS AGENTES

| agente | recibe → devuelve (JSON) | decide |
|---|---|---|
| Intérprete<br>prompt v3 | la pregunta (y el motivo de un rechazo) → la mención consultada, los otros ramos, la frase del período y el período | entregar, corregir su lectura tras un rechazo o `sin_ramo` |
| Resolvedor<br>prompt v2 | la mención, los otros ramos y 5 candidatos → un código | elegir, llamar a T1 con otra consulta o `ninguno`, que vuelve al Intérprete |
| Verificador<br>prompt v4 | la pregunta, el ramo, el período y los otros → citas y veredicto | aceptar, que entrega a T2, o rechazar con problema y motivo |

**Por qué tres.** Cada agente atiende una falla. El Intérprete lee la prosa (M2, M3) sin ver el catálogo, así que no puede copiar mal un código, que era M1 en el D2. El Resolvedor es el único que compara la mención con el catálogo, para abreviaturas y nombres incompletos. El Verificador es el único que ve juntas la pregunta y la elección, para atrapar un ramo o un período tomados de otra parte. Las reglas siguen en el programa porque en el D2 el modelo las aplicó bien solo en el 31,7 % de los casos con la ficha correcta delante.

**Por qué B y C no suben el acierto.** En 330 casos B buscó de nuevo en 8 y C rechazó en 10. Pero en 313 la respuesta final es el primer candidato de T1, casi siempre correcto, y ahí la v4 da lo que daría un *workflow*, un camino fijo en código que la clase 7 (Anthropic, 2024) separa de un agente. B se apartó de él en 16 casos y acertó 1, y en 7 eligió el ramo de número vecino ("cálculo 3"). C detecta errores (sin T1, sus 21 rechazos eran fundados), pero con T1 la mitad de sus 10 rechazos fueron a respuestas correctas, y un rechazo fundado volvía al Intérprete, que no ve el catálogo. Esto se vio después de medir. La v5 mandó el rechazo a B y no superó a la v4 en desarrollo (186 y 194 contra 196 en 223 casos). En la v6, con historial y pregunta, B acertó 108 de los 147 que decidió, el primero de T1 111 y el primero aún inscribible 124.

## RESULTADOS

| | corrida del 20 oct (120 + 30) | | | réplica, sellados (120 + 60) | | |
|---|---|---|---|---|---|---|
| acierto conjunto | plantilla | redact. | **150** | plantilla | redact. | **180** |
| baseline zero-shot (D1) | – | – | – | 7 | 4 | 11 |
| baseline few-shot (D1) | 28 | 7 | 35 | 30 | 13 | 43 |
| sistema del D2 | 72 | 24 | 96 | 76 | 42 | 118 |
| regla fija, sin modelo | 83 | 7 | 90 | 77 | 25 | 102 |
| **tres agentes** | **103** | **29** | **132** | **109** | **55** | **164** |
| y además ramo y período bien | 97 | 24 | 121 | 103 | 55 | 158 |

En los 150, entre los casos que solo uno de los dos acierta, los agentes ganan 39 a 3 al D2 (McNemar exacto, $p < 0{,}001$). En las 30 redactadas, 6 a 1 ($p = 0{,}125$). Como los 150 se usaron después para diseñar una v5, la v4 se midió de nuevo, con protocolo previo, en 180 sellados. Gana 50 a 4 ($p < 0{,}001$) y 14 a 1 en las 60 redactadas.

La regla fija toma el texto tras "inscribir", "tomar" o "meter", lo busca con T1 y supone el semestre actual. En las redactadas cae a 7 de 30 y 25 de 60. El zero-shot se agregó en la réplica. Por mecanismo, en los 105 de plantilla no ambiguos del 20 de octubre:

| acierta el ramo, cuando la pregunta... | casos | D2 | agentes |
|---|---|---|---|
| trae el nombre exacto (M1) | 69 | 44 | **67** |
| lo abrevia o usa otro nombre | 36 | 19 | **33** |
| nombra otro ramo antes (M2, ya contado arriba) | 35 | 7 | **34** |
| acierta el período (M3) | 105 | 90 | **98** |

## TÉCNICAS Y ABLACIÓN

| sin... (Lecture 5) | agente | apunta a | acierto | Δ | pares |
|---|---|---|---|---|---|
| la búsqueda T1 (uso de herramienta) | B | M1 | 100 | −64 | 64 a 0 |
| 4 ejemplos (few-shot) | A | M2, M3 | 151 | −13 | 16 a 3 |
| la lista de otros ramos (descomposición) | A | M2 | 169 | +5 | 1 a 6 |
| la regla del verbo (claro y directo) | A | M2 | 164 | 0 | 0 a 0 |
| citar antes de decidir (quotes first) | A | M3 | 159 | −5 | 9 a 4 |
| citar antes de decidir (quotes first) | C | M2, M3 | 164 | 0 | 0 a 0 |
| 2 ejemplos (few-shot) | C | M2 | 164 | 0 | 0 a 0 |
| el Verificador entero | C | M2, M3 | 164 | 0 | 0 a 0 |
| el Resolvedor, se toma el top-1* | B | M1 | 168 | +4 | 0 a 4 |

Cada fila quita una pieza al sistema completo (164 de 180). "Pares": casos que solo acierta el completo, a casos que solo acierta la versión sin la pieza. (*) Mide si B aporta. "Apunta a" se fijó antes de correr. **Técnicas por agente** (diapositiva de la Lecture 5). A: rol (6), 4 ejemplos (few-shot, 7), citar antes de decidir (pedir citas, 24), lista de otros ramos (descomposición, que la clase no nombra) y regla del verbo (claro y directo, 20). B: T1 (herramienta, 27) y reglas sobre siglas y números (claro y directo). C: citar antes de comparar y 2 ejemplos. No se quitaron el rol, la salida JSON ni las reglas de B. Con la corrección de Holm, calculada después, siguen significativos T1 ($p < 0{,}001$) y los ejemplos (ajustado $p = 0{,}035$), que también restaron en los 150 (9 a 0).

Lo que más resta es quitar T1 y después los ejemplos. Sin T1 el Resolvedor elige entre los 61 ramos y acierta el abreviado en 9 de 34, contra 33. Sin ejemplos, el Intérprete acierta 27 de 38 preguntas que nombran otro ramo antes, contra 36. Sin citar el período lo acierta en 154 contra 173 (con ramo y período bien, 21 a 4, $p < 0{,}001$), pero muchas reglas no dependen de él.

## CASO DE FALLA

Es el primer redactado que falla, elegido con una regla fijada antes de correr. "...quería tomar marketing el otro semestre, en marzo". El Intérprete respondió "proximo", que era correcto. El Verificador lo rechazó porque leyó "el otro semestre" como el actual. El Intérprete cambió a "actual" y T2 respondió "no", cuando correspondía "condicional". Es el único de los 150 en que el Verificador cambió el resultado.

## CÓMO SE MIDIÓ

**Conjuntos.** Originales, los 60 casos del D1. Nuevos, 60 del D2. Ambos con preguntas de plantilla del generador. Redactados, preguntas escritas fuera de ellas: 30 en la corrida del 20 de octubre y 60 entre los 180 sellados el 21 de octubre. Las escribió un subagente de Claude sin acceso a los prompts, con el ramo, el período y el ramo de contexto de cada caso. Lucas leyó las 60 antes de sellarlas y las 30 después de la corrida. Claude corrigió la redacción de 3 de las 30, que repiten los problemas de 30 originales con otra prosa. `preparar_redactados.py` describe lo que recibió el subagente, pero el texto exacto de su instrucción no se guardó. Los 180 tienen su sha256 en `SELLO.txt` desde antes de usarse ("sellados"). **Procedimiento.** Los prompts se ajustaron en 52 casos y 21 redactadas de desarrollo. La versión final, la v4, se aceptó con una regla escrita antes de correrla. Las tres corridas de prueba tienen su protocolo en el repositorio desde antes de correr. Cada mensaje entre agentes queda en `trazas/` con el hash del prompt que lo produjo. **Video.** Corre con `demo_d3_colab.ipynb` los redactados 0, 3 y 16 (el caso de falla), compara cada mensaje con la traza guardada y termina con una pregunta escrita en el momento.

## LÍMITES DECLARADOS

**Etiquetas.** Las genera el mismo motor de reglas que usa T2. Se mide la lectura de la pregunta, no si el reglamento codificado es el real. **Ambiguos.** En plantilla, 15 de 120 (en los 150) y 14 de 120 (en los 180) nombran el ramo con una forma que sirve para varios, como "gestión". **Parecido con la prueba.** El puntaje de T1 y el diagnóstico M1 a M3 se hicieron mirando originales y nuevos. El prompt del Intérprete nombra los verbos de las plantillas. Las redactadas selladas traen el nombre exacto del catálogo en 48 de 60, contra 39 y 35 en plantilla, y en 40 de 60 el período del ramo consultado va con las palabras que recibió el redactor ("este semestre", "próximo semestre"), lo que las facilita. De los 180, hay 38 que repiten historial y consulta de un caso anterior, 30 con otra pregunta y 8 con la misma. Sin ellos, fuera del protocolo, los agentes ganan al D2 34 a 4. Las ablaciones se pasaron de los 150 a los 180 con un protocolo nuevo escrito antes de correrlas.