Un sistema de tres agentes sobre Phi-3.5-mini (3,8B) acierta 88,0 % contra 64,0 % del D2 en 150 casos, y 91,1 % contra 65,6 % en 180 casos sellados

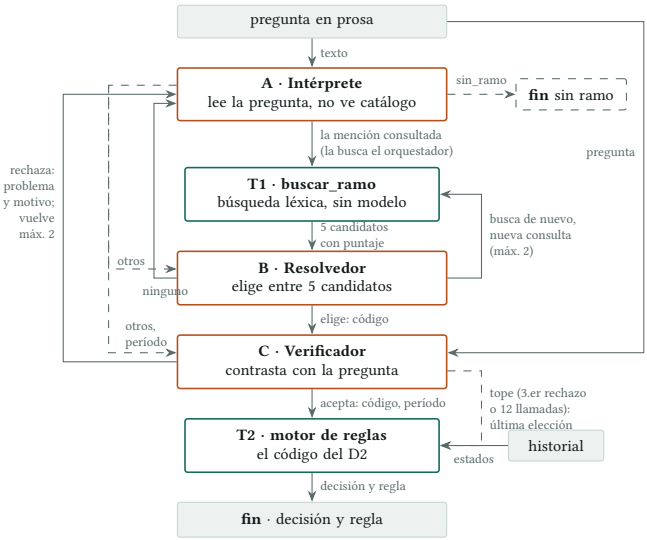
Deliverable 3 · Generative Artificial Intelligence (580694) · Universidad de Concepción · 31 de octubre de 2026
Grupo 3: Joaquín Sepúlveda · Renato Saavedra · Lucas Saldivia • **Modelo:** `microsoft/Phi-3.5-mini-instruct` (revisión `2fe1924`), 3,8B, NF4, T4 de Colab, en los tres agentes
Repositorio: `github.com/Luquitas02/genai-inscripcion-ramos` • **Video:** `https://youtu.be/UYir4ZV0sjM`

TAREA, FALLA Y CONTINUIDAD

La tarea y el criterio son los del D1 y el D2. Dado el historial de un estudiante y una pregunta en prosa, el sistema decide si puede inscribir el ramo y cita la regla. Un caso es correcto si acierta decisión y regla (acierto conjunto). El D2 acertaba 35 de los 60 casos del D1. Su modelo solo leía la pregunta, y el programa armaba la ficha del estudiante y aplicaba el reglamento. Así desaparecieron los cuatro errores de razonamiento del D1 (E1 a E4), aunque el D1 dejaba dos de ellos para el D3. Con el ramo y el período correctos el programa acierta siempre, porque las etiquetas salen de ese mismo programa. Todo el error restante estaba en la lectura de la pregunta, el paso 1 del D2. El D3 rehace esa lectura con tres agentes sobre el mismo Phi.

En esos 60 casos la lectura del D2 fallaba por tres mecanismos. **M1** es elegir el código del ramo. Con el nombre exacto del ramo en la pregunta, Phi acertaba 18 de 34: de la lista de los 61 ramos sacaba un código que existe, pero de otro ramo. **M2** es separar el ramo consultado de los otros. Si la pregunta nombra otro ramo antes del consultado, acertaba 3 de 20. **M3** es el período. Si la pregunta dice que otro ramo se cursa "ahora", Phi tomaba ese "ahora" como el período del ramo consultado.

EL GRAFO DE AGENTES



Borde naranjo, agentes, cada uno con su prompt en `prompts/<agente>.md`. Borde verde, herramientas. Las vueltas al Intérprete, por rechazo o por `ninguno` (que pasa el problema "ramo"), suman máx. 2. El tope de 12 llamadas corta en cualquier agente. Al llegar a un tope, o si A responde `sin_ramo` tras un rechazo, T2 recibe la última elección aunque esté rechazada; si aún no hubo elección, el caso termina sin ramo. Un orquestador en código ejecuta la decisión de cada agente.

Traza real (conjunto nuevos, caso 49). T1 da un puntaje léxico, y 1,50 es coincidencia exacta:

"...me falta programación pero la estoy cursando, ¿puedo tomar opti I el que viene?"

```
A⟶T1 {"consultado": "opti I", "otros": ["programación"], "frase_periodo": "el
que viene", "periodo": "proximo"}
T1⟶B 580315 Optimización I 0,60 · 201 Complementaria 1 0,55 · ...
B⟶T1 {"accion": "buscar", "consulta": "Optimización I"}
T1⟶B 580315 Optimización I 1,50 · 580325 Optimización II 0,93 · ...
B⟶C {"accion": "elegir", "codigo": "580315"}
C⟶T2 {"cita_ramo": "Optimización I", "cita_periodo": "proximo (2027-1)",
"accion": "aceptar"}
T2 condicional · R-DEPENDE-APROBACION (correcta)
```

LOS AGENTES

agente	recibe ⟶ devuelve (JSON)	herr.	decide
Intérprete prompt v3	la pregunta (y el motivo de un rechazo) ⟶ mención, otros ramos, frase del período y período	–	entregar, corregir su lectura tras un rechazo o `sin_ramo`
Resolvedor prompt v2	la mención, los otros y 5 candidatos de T1 ⟶ un código	T1	elegir, buscar con otra consulta o `ninguno` (vuelve a A)
Verificador prompt v4	la pregunta, el ramo, el período y los otros ⟶ citas y veredicto	–	aceptar (pasa a T2) o rechazar con problema y motivo

Por qué tres. Cada agente se diseñó para una falla. El Intérprete lee la prosa (M2, M3) sin ver el catálogo, así que no elige códigos, que era M1 en el D2. El Resolvedor es el único que compara la mención con el catálogo, para abreviaturas y nombres incompletos. El Verificador es el único que ve juntas la pregunta y la elección, para atrapar un ramo o un período tomados de otra parte. Las reglas siguen en código: en el D2 el modelo las aplicó bien solo en el 31,7 % de los casos, aun con la ficha correcta.

Lo que mostró la medición: B y C no aportan. En 330 casos B buscó de nuevo en 8 y C rechazó en 10. En 313 la respuesta final es el primer candidato de T1 con la primera lectura del Intérprete: un camino fijo, lo que la clase 7 (Anthropic, 2024) llama *workflow* y no agente. Ese camino, sin B ni C, acierta 134 de 150 y 168 de 180, más que el sistema. B se apartó de T1 en 16 casos y acertó 1, y en 7 eligió el ramo de número vecino ("cálculo 3"). C detecta errores (en los 180 sin T1, sus 21 rechazos eran fundados), pero con T1 la mitad de sus 10 rechazos fueron a respuestas correctas, y un rechazo fundado volvía al Intérprete, que no ve el catálogo: ningún rechazo arregló un caso y uno causó el caso de falla. La mejora sobre el D2 viene del Intérprete y de T1; sin T1 los agentes bajan a 100 de 180, bajo el D2. Se vio después de medir; la v5 y la v6, que corregían B y C, no mejoraron a la v4 con significancia (v6: 363 contra 360, $p = 0{,}61$).

RESULTADOS

	corrida del 20 oct (120 + 30)			réplica, sellados (120 + 60)		
acierto conjunto	plantilla	redact.	**150**	plantilla	redact.	**180**
baseline zero-shot (D1)	–	–	–	7	4	11
baseline few-shot (D1)	28	7	35	30	13	43
sistema del D2	72	24	96	76	42	118
regla fija, sin modelo	83	7	90	77	25	102
tres agentes	**103**	**29**	**132**	**109**	**55**	**164**
y además ramo y período bien	97	24	121	103	55	158

En los 150, entre los casos que solo uno de los dos acierta, los agentes ganan 39 a 3 al D2 (McNemar exacto, $p < 0{,}001$). En las 30 redactadas, 6 a 1 ($p = 0{,}125$). Como los 150 se usaron después para diseñar una v5, la v4 se midió de nuevo, con protocolo previo, en 180 sellados. Gana 50 a 4 ($p < 0{,}001$) y 14 a 1 en las 60 redactadas.

La regla fija toma el texto tras "inscribir", "tomar" o "meter", lo busca con T1 y supone el semestre actual. En las redactadas cae a 7 de 30 y 25 de 60. El zero-shot se agregó en la réplica. Por mecanismo, en los 105 de plantilla no ambiguos del 20 de octubre:

acierta el ramo, cuando la pregunta...	casos	D2	agentes
trae el nombre exacto (M1)	69	44	**67**
lo abrevia o usa otro nombre	36	19	**33**
nombra otro ramo antes (M2, ya contado arriba)	35	7	**34**
acierta el período (M3)	105	90	**98**

TÉCNICAS Y ABLACIÓN

sin... (Lecture 5)	agente	apunta a	acierto	Δ	pares
la búsqueda T1 (uso de herramienta)	B	M1	100	−64	64 a 0
4 ejemplos (few-shot)	A	M2, M3	151	−13	16 a 3
la lista de otros ramos (descomposición)	A	M2	169	+5	1 a 6
la regla del verbo (claro y directo)	A	M2	164	0	0 a 0
citar antes de decidir (quotes first)	A	M3	159	−5	9 a 4
citar antes de decidir (quotes first)	C	M2, M3	164	0	0 a 0
2 ejemplos (few-shot)	C	M2	164	0	0 a 0
el Verificador entero	C	M2, M3	164	0	0 a 0
el Resolvedor, se toma el top-1*	B	M1	168	+4	0 a 4

Cada fila quita una pieza al sistema completo (164 de 180). "Pares": casos que solo acierta el completo, a casos que solo acierta la versión sin la pieza. (*) Mide si B aporta. T1 la llama el orquestador antes de B, y quitarla le quita a B la acción de buscar. Sin la lista de otros, B y C tampoco la reciben; esa fila y top-1 suben sin significancia y el sistema, fijado antes, no se cambió. "Apunta a" se fijó antes de correr. **Técnicas por agente** (diapositiva de la Lecture 5). A: rol (6), 4 ejemplos (few-shot, 7), citar antes de decidir (pedir citas, 24), lista de otros ramos (descomposición, que la clase no nombra) y regla del verbo (claro y directo, 20). B: T1 (herramienta, 27) y reglas sobre siglas y números (claro y directo). C: citar antes de comparar y 2 ejemplos. No se quitaron el rol, la salida JSON ni las reglas de B (su protocolo no se corrió a tiempo). Con la corrección de Holm, calculada después, siguen significativos T1 ($p < 0{,}001$) y los ejemplos (ajustado $p = 0{,}035$), que también restaron en los 150 (9 a 0).

Sin T1 el Resolvedor elige entre los 61 ramos y acierta el abreviado en 9 de 34, contra 33. Sin ejemplos, el Intérprete acierta 27 de 38 preguntas que nombran otro ramo antes, contra 36. Sin citar el período lo acierta en 154 contra 173 (con ramo y período bien, 21 a 4, $p < 0{,}001$), pero muchas reglas no dependen de él.

CASO DE FALLA

Es el primer redactado que falla, elegido con una regla fijada antes de correr. "...quería tomar marketing el otro semestre, en marzo". El Intérprete respondió "proximo", que era correcto. El Verificador lo rechazó porque leyó "el otro semestre" como el actual. El Intérprete cambió a "actual" y T2 respondió "no", cuando correspondía "condicional". Es el único de los 150 en que el Verificador cambió el resultado.

CÓMO SE MIDIÓ

Conjuntos. Originales, los 60 casos del D1. Nuevos, 60 del D2. Ambos con preguntas de plantilla del generador. Redactados, preguntas escritas fuera de ellas: 30 en la corrida del 20 de octubre y 60 entre los 180 sellados el 21 de octubre. Las escribió un subagente de Claude sin acceso a los prompts, con el ramo, el período y el ramo de contexto de cada caso. Lucas leyó las 60 antes de sellarlas y las 30 después de la corrida. Claude corrigió la redacción de 3 de las 30, que repiten los problemas de 30 originales con otra prosa. Su instrucción exacta no se guardó (la describe `preparar_redactados.py`). Los 180 tienen su sha256 en `SELLO.txt` desde antes de usarse ("sellados"). **Procedimiento.** Los prompts se ajustaron en 52 casos y 21 redactadas de desarrollo. La versión final, la v4, se aceptó con una regla escrita antes de correrla. Las tres corridas de prueba tienen su protocolo en el repositorio desde antes de correr. Cada mensaje entre agentes queda en `trazas/` con el hash del prompt que lo produjo. **Video.** Los redactados 0, 3 y 16 (el de falla), cada mensaje comparado con su traza, y una pregunta que no está en ningún conjunto.

LÍMITES DECLARADOS

Etiquetas. Las genera el mismo motor de reglas que usa T2. Se mide la lectura de la pregunta, no si el reglamento codificado es el real. **Ambiguos.** En plantilla, 15 de 120 (en los 150) y 14 de 120 (en los 180) nombran el ramo con una forma que sirve para varios, como "gestión". **Parecido con la prueba.** El puntaje de T1 y el diagnóstico M1 a M3 se hicieron mirando originales y nuevos. El prompt del Intérprete nombra los verbos de las plantillas. Las redactadas selladas traen el nombre exacto del catálogo en 48 de 60, contra 39 y 35 en plantilla, y en 40 de 60 el período del ramo consultado va con las palabras que recibió el redactor ("este semestre", "próximo semestre"), lo que las facilita. De los 180, hay 38 que repiten historial y consulta de un caso anterior, 30 con otra pregunta y 8 con la misma. Sin ellos, fuera del protocolo, los agentes ganan al D2 34 a 4. En los 150, 8 preguntas de nuevos repiten una de originales. **Citas.** El Verificador cita fuera de la pregunta en 38 de 180 casos, como en la traza.